Trabajo Práctico 5: IA en Azure con Machine Learning Automatizado

Predicción de precios de automóviles con Azure AutoML (sin código)

Carrera: Ingeniería de Software
Asignatura: Tecnología Cloud con AWS
Modalidad: Individual

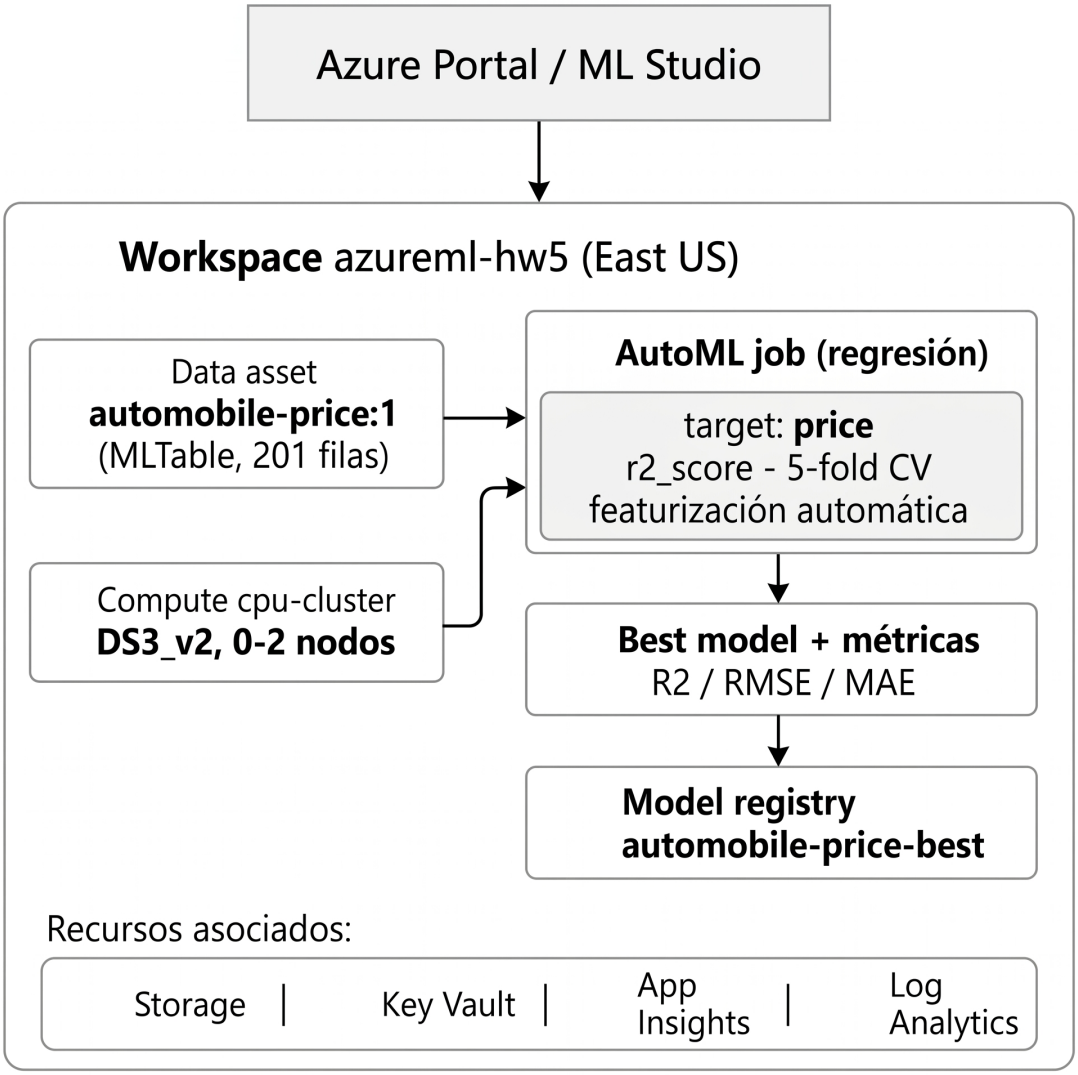
Integrante: DIEGO ANDREE VALENCIA VASQUEZ
Fecha: Octubre 2026

Repositorio: CloudTask

1. Objetivo

Comprender los aspectos básicos de la inteligencia artificial en Azure, aplicando los principios de IA responsable, creando un workspace de Azure Machine Learning y entrenando un modelo predictivo de regresión con AutoML sin escribir código, para luego evaluar su rendimiento (R^2, RMSE, MAE).

2. Diagrama de arquitectura



3. Servicios y componentes

Componente	Recurso	Propósito
Grupo de recursos	rg-cloudtask-hw5 (East US)	Límite de administración y costos
Azure ML Workspace	azureml-hw5	Experimentos, datos, cómputo y modelos
Compute target	cpu-cluster (Standard_DS3_v2, 0–2 nodos)	Entrenamiento; escala a cero
Data asset	automobile-price:1 (MLTable, 201 filas)	Dataset UCI Automobile, target price
AutoML job	serene_head_1hrtd6fdbz	Regresión con 5-fold CV y explainability
Model registry	automobile-price-best	Registro/versionado del mejor modelo
Servicios asociados	Storage, Key Vault, App Insights, Log Analytics	Datos, secretos, telemetría

4. Procedimiento realizado (Azure CLI)

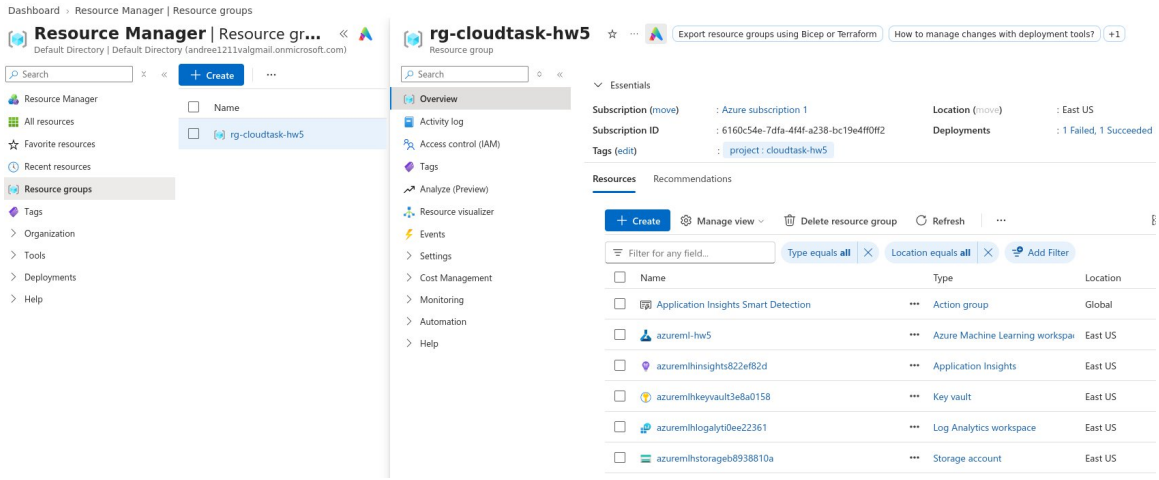
- Instalación de Azure CLI 2.91 + extensión ml, inicio de sesión con cuenta personal y verificación de suscripción.
- Creación del grupo de recursos rg-cloudtask-hw5 en East US y del workspace azureml-hw5.
- Configuración del compute target cpu-cluster (Standard_DS3_v2, mínimo 0, máximo 2, idle 5 min).
- Curación del dataset UCI Automobile (201 filas; faltantes como vacío) y registro como data asset MLTable.
- Configuración del experimento AutoML: regresión, target price, métrica R^2, 5-fold CV, 10 trials, 20 min.
- Ejecución del entrenamiento y revisión de métricas; registro del mejor modelo en el workspace.

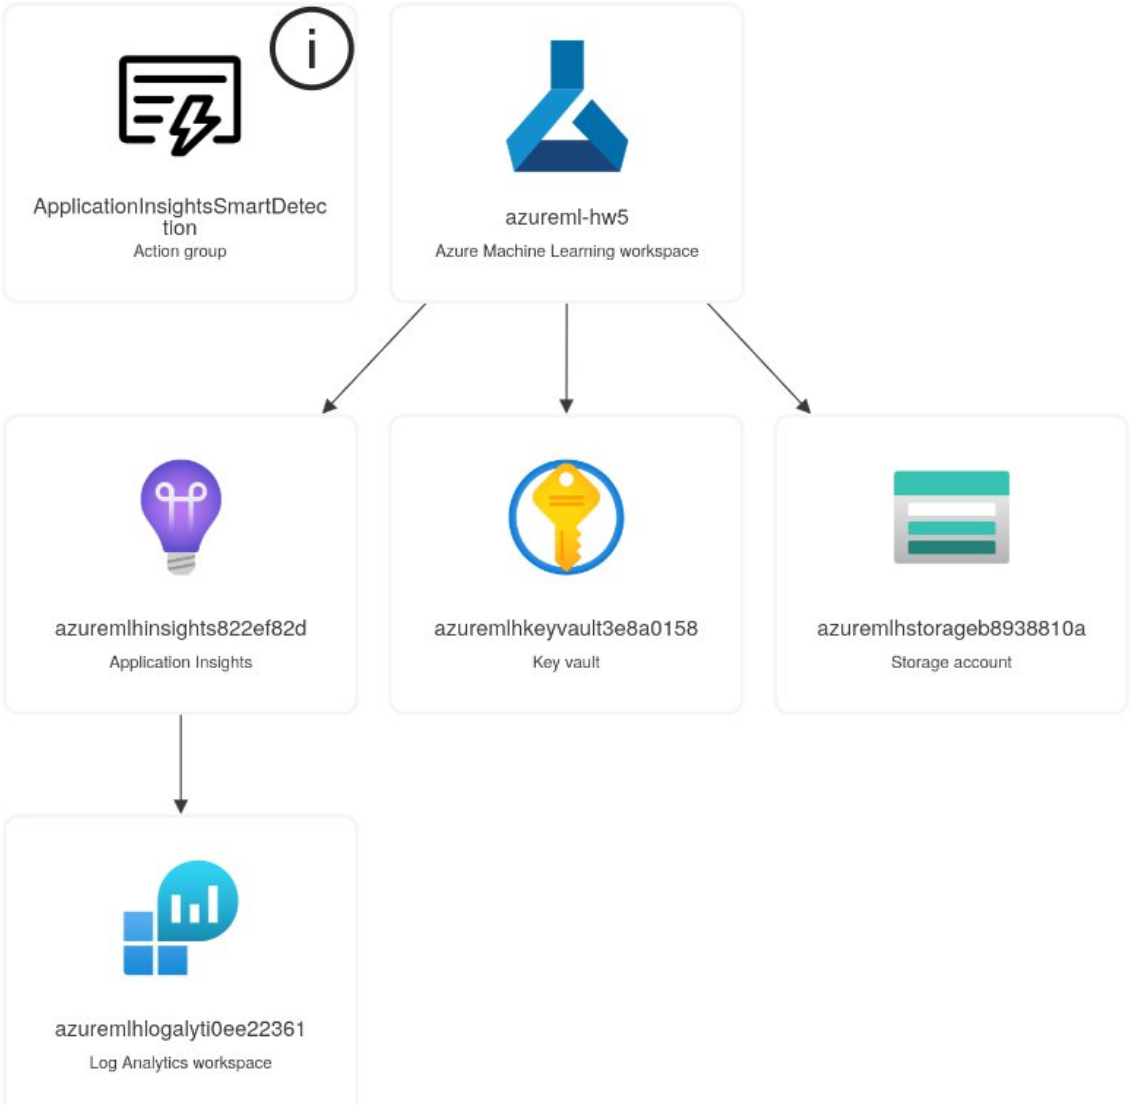
```
az ml job create --file infra/azureml/automl-automobile.yml \
  --resource-group rg-cloudtask-hw5 --workspace-name azureml-hw5
```

5. Evidencia de la implementación (capturas)

[Captura 1] Grupo de recursos rg-cloudtask-hw5 con todos los recursos.

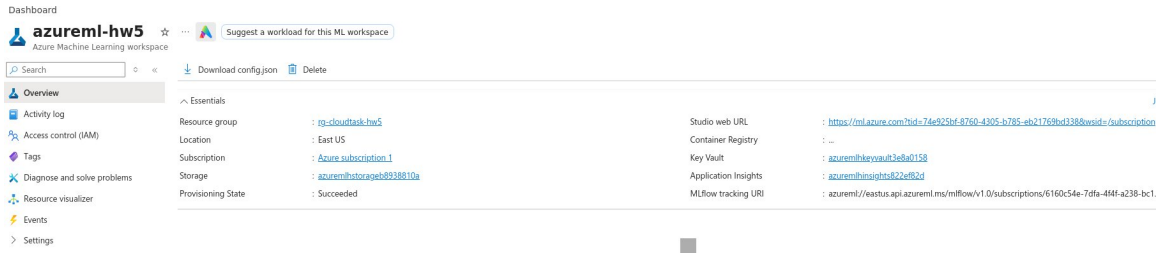
Portal > Grupos de recursos > rg-cloudtask-hw5.





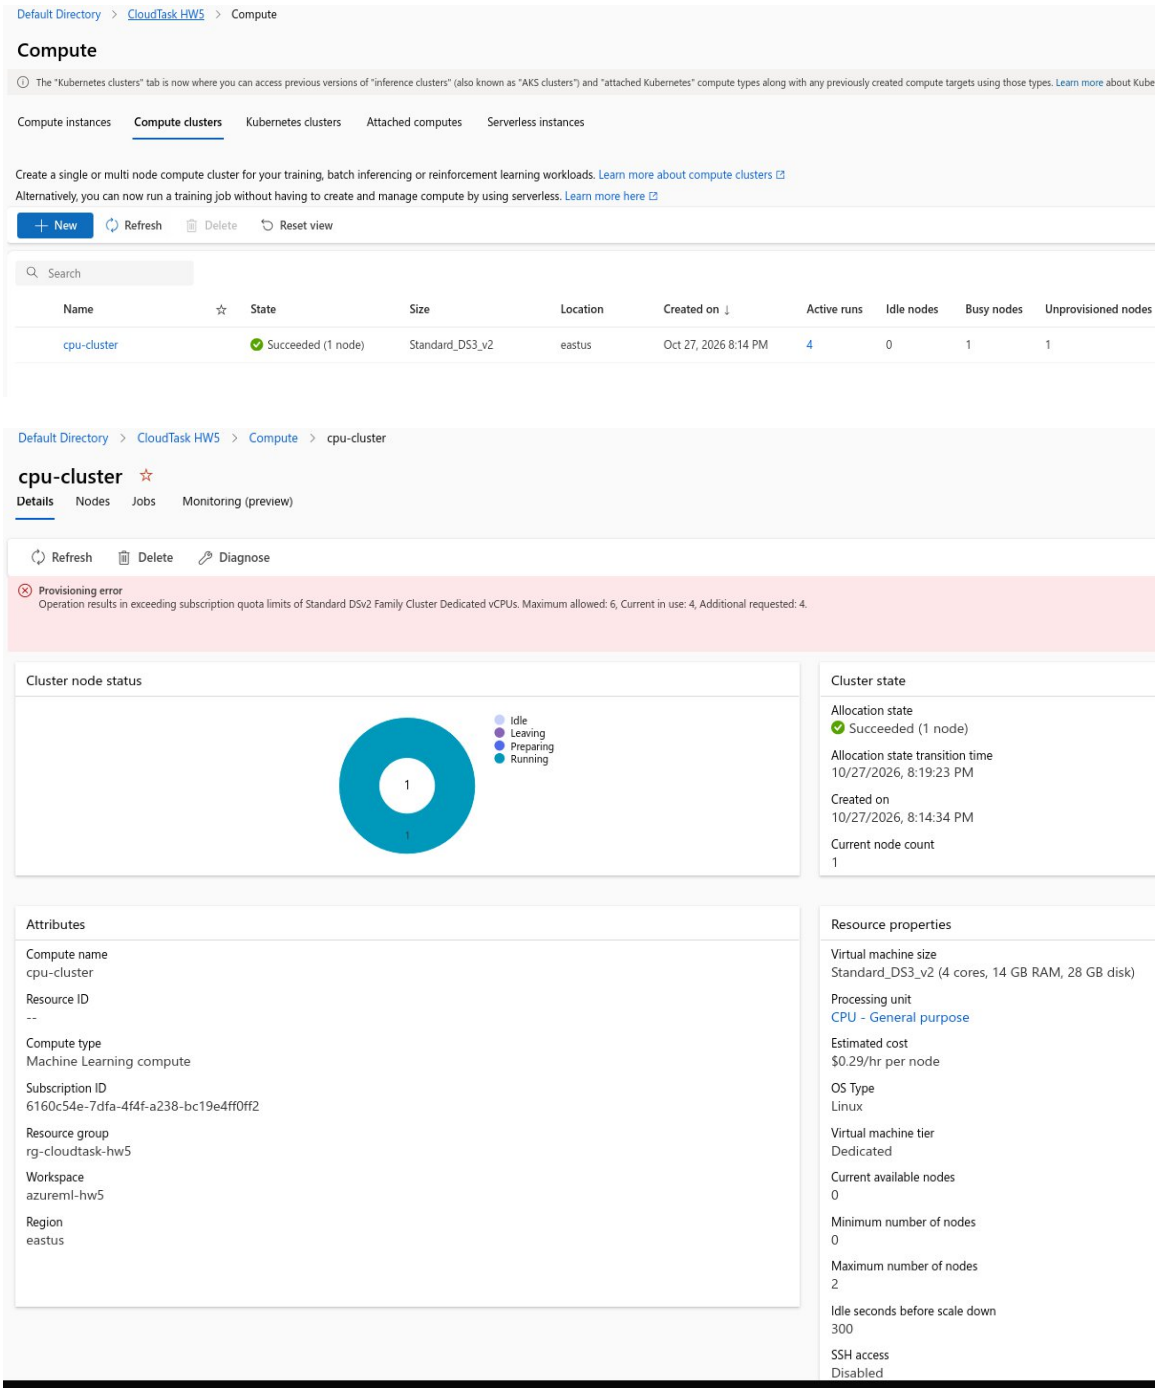
[Captura 2] Workspace azureml-hw5 — vista general.

Portal > azureml-hw5 > Información general.



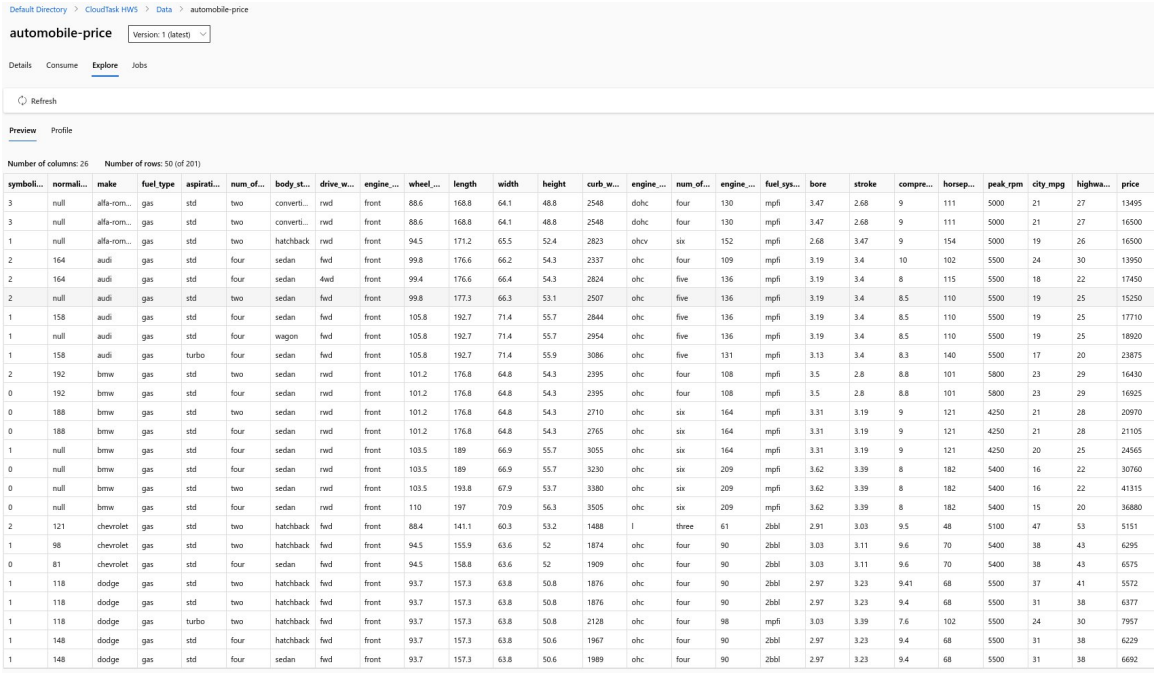
[Captura 3] Compute cpu-cluster (AmlCompute, DS3_v2, 0–2 nodos).

ml.azure.com > Compute > Compute clusters, o Portal > workspace > Compute.



[Captura 4] Data asset automobile-price v1 con vista previa.

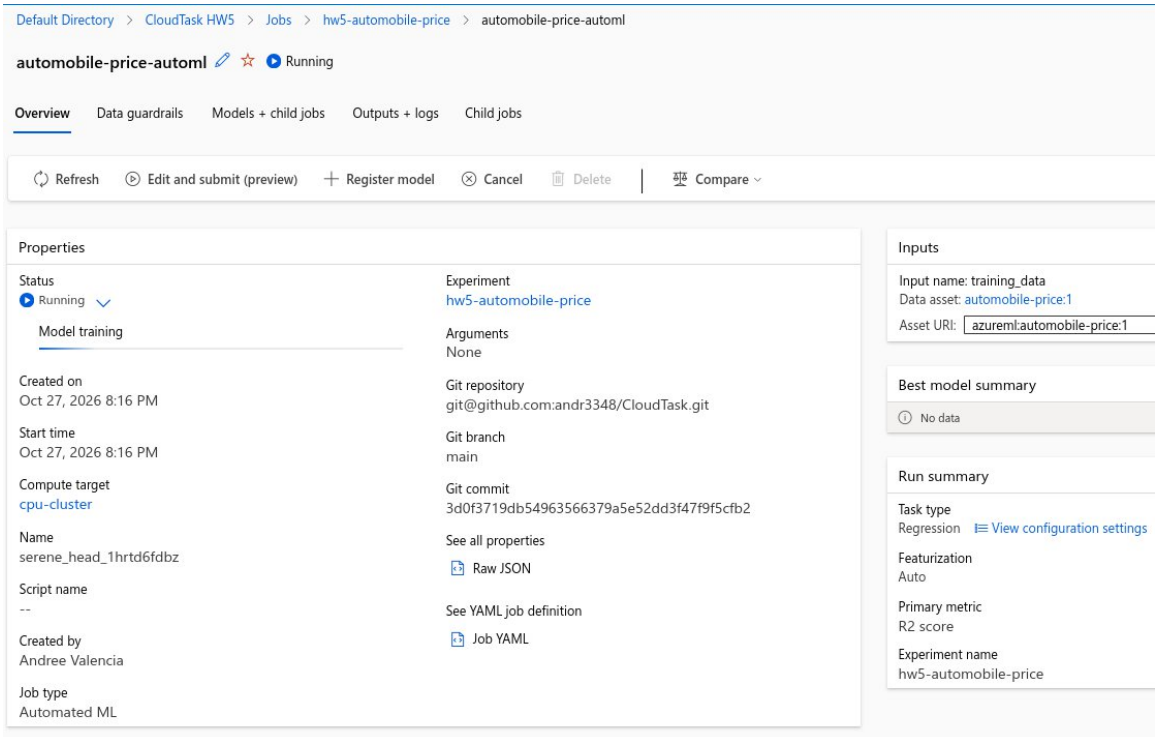
ML Studio > Data > automobile-price > versión 1 > Preview.



symboli...	normali...	make	fuel_type	aspirati...	num_of...	body_st...	drive_w...	engine_...	wheel_...	length	width	height	curb_w...	engine_...	num_of...	engine_...	fuel_sys...	bore	stroke	compre...	horsep...	peak_rpm	city_mpg	highwa...	price
3	null	alfa-rom...	gas	std	two	converti...	rwd	front	88.6	168.8	64.1	48.8	2548	dohc	four	130	mpfi	3.47	2.68	9	111	5000	21	27	13495
3	null	alfa-rom...	gas	std	two	converti...	rwd	front	88.6	168.8	64.1	48.8	2548	dohc	four	130	mpfi	3.47	2.68	9	111	5000	21	27	16500
1	null	alfa-rom...	gas	std	two	hatchback	rwd	front	94.5	171.2	65.5	52.4	2823	ohcv	six	152	mpfi	2.68	3.47	9	154	5000	19	26	16500
2	164	audi	gas	std	four	sedan	fwd	front	99.8	176.6	66.2	54.3	2337	ohc	four	109	mpfi	3.19	3.4	10	102	5500	24	30	13950
2	164	audi	gas	std	four	sedan	4wd	front	99.4	176.6	66.4	54.3	2824	ohc	five	136	mpfi	3.19	3.4	8	115	5500	18	22	17450
2	null	audi	gas	std	two	sedan	fwd	front	99.8	177.3	66.3	53.1	2507	ohc	five	136	mpfi	3.19	3.4	8.5	110	5500	19	25	15250
1	158	audi	gas	std	four	sedan	fwd	front	105.8	192.7	71.4	55.7	2844	ohc	five	136	mpfi	3.19	3.4	8.5	110	5500	19	25	17710
1	null	audi	gas	std	four	wagon	fwd	front	105.8	192.7	71.4	55.7	2954	ohc	five	136	mpfi	3.19	3.4	8.5	110	5500	19	25	18920
1	158	audi	gas	turbo	four	sedan	fwd	front	105.8	192.7	71.4	55.9	3086	ohc	five	131	mpfi	3.13	3.4	8.3	140	5500	17	20	23875
2	192	bmw	gas	std	two	sedan	rwd	front	101.2	176.8	64.8	54.3	2395	ohc	four	108	mpfi	3.5	2.8	8.8	101	5800	23	29	16430
0	192	bmw	gas	std	four	sedan	rwd	front	101.2	176.8	64.8	54.3	2395	ohc	four	108	mpfi	3.5	2.8	8.8	101	5800	23	29	16925
0	188	bmw	gas	std	two	sedan	rwd	front	101.2	176.8	64.8	54.3	2710	ohc	six	164	mpfi	3.31	3.19	9	121	4250	21	28	20970
0	188	bmw	gas	std	four	sedan	rwd	front	101.2	176.8	64.8	54.3	2765	ohc	six	164	mpfi	3.31	3.19	9	121	4250	21	28	21105
1	null	bmw	gas	std	four	sedan	rwd	front	103.5	189	66.9	55.7	3055	ohc	six	164	mpfi	3.31	3.19	9	121	4250	20	25	24565
0	null	bmw	gas	std	four	sedan	rwd	front	103.5	189	66.9	55.7	3230	ohc	six	209	mpfi	3.62	3.39	8	182	5400	16	22	30760
0	null	bmw	gas	std	two	sedan	rwd	front	103.5	193.8	67.9	53.7	3380	ohc	six	209	mpfi	3.62	3.39	8	182	5400	16	22	41315
0	null	bmw	gas	std	four	sedan	rwd	front	110	197	70.9	56.3	3505	ohc	six	209	mpfi	3.62	3.39	8	182	5400	15	20	36880
2	121	chevrolet	gas	std	two	hatchback	fwd	front	88.4	141.1	60.3	53.2	1488	l	three	61	2bbl	2.91	3.03	9.5	48	5100	47	53	5151
1	98	chevrolet	gas	std	two	hatchback	fwd	front	94.5	155.9	63.6	52	1874	ohc	four	90	2bbl	3.03	3.11	9.6	70	5400	38	43	6295
0	81	chevrolet	gas	std	four	sedan	fwd	front	94.5	158.8	63.6	52	1909	ohc	four	90	2bbl	3.03	3.11	9.6	70	5400	38	43	6575
1	118	dodge	gas	std	two	hatchback	fwd	front	93.7	157.3	63.8	50.8	1876	ohc	four	90	2bbl	2.97	3.23	9.41	68	5500	37	41	5572
1	118	dodge	gas	std	two	hatchback	fwd	front	93.7	157.3	63.8	50.8	1876	ohc	four	90	2bbl	2.97	3.23	9.4	68	5500	31	38	6377
1	118	dodge	gas	turbo	two	hatchback	fwd	front	93.7	157.3	63.8	50.8	2128	ohc	four	98	mpfi	3.03	3.39	7.6	102	5500	24	30	7957
1	148	dodge	gas	std	four	hatchback	fwd	front	93.7	157.3	63.8	50.6	1967	ohc	four	90	2bbl	2.97	3.23	9.4	68	5500	31	38	6229
1	148	dodge	gas	std	four	sedan	fwd	front	93.7	157.3	63.8	50.6	1989	ohc	four	90	2bbl	2.97	3.23	9.4	68	5500	31	38	6692

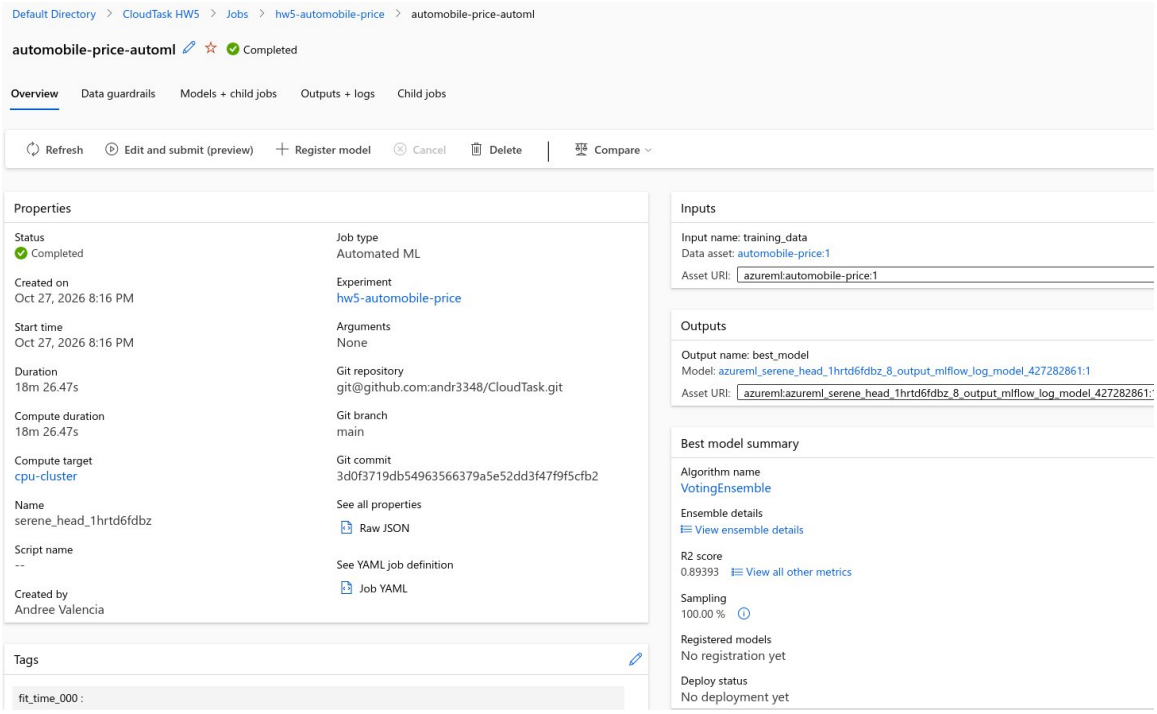
[Captura 5] AutoML job: configuración/estado en ejecución.

ML Studio > Jobs > hw5-automobile-price > job serene_head_1hrtd6fdbz.



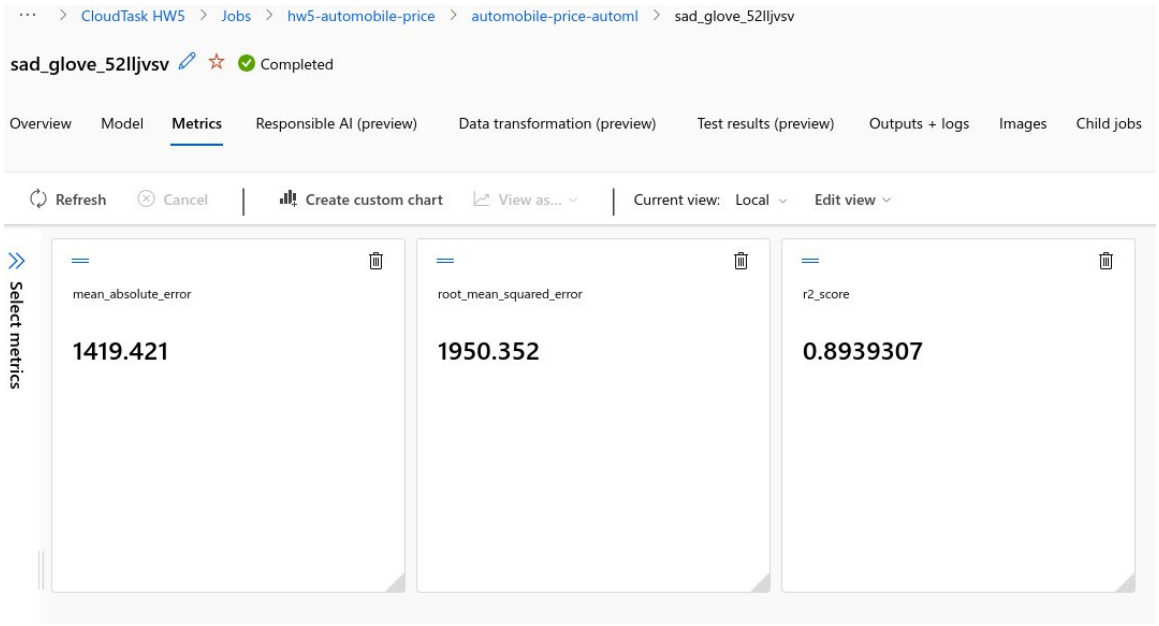
[Captura 6] Job completado — «Best model summary» en Details/Overview.

ML Studio > Jobs > hw5-automobile-price > serene_head_1hrtd6fdbz. La página de detalles muestra Estado Completed y la tarjeta «Best model summary» con el algoritmo ganador (VotingEnsemble) y su R².



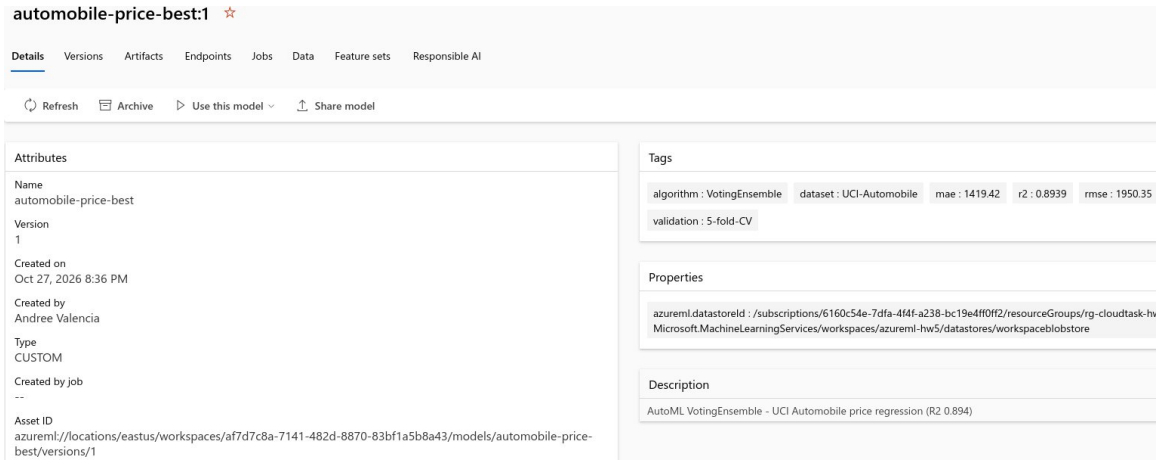
[Captura 6b] Métricas del mejor modelo (R², RMSE, MAE y gráficos).

«Models + child jobs», hacer clic en el algoritmo ganador (VotingEnsemble, el de mayor R²) y entrar a la pestaña «Metrics»; marcar R², RMSE y MAE.



[Captura 7] Modelo registrado automobile-price-best (tags con r2/rmse/mae).

ML Studio > Models > automobile-price-best > pestaña «Tags»/«Details».



6. Resultados del modelo

Métrica	Valor	Interpretación
R^2 (coeficiente de determinación)	0.8939	Proporción de la varianza del precio explicada
RMSE	1950.35	Error medio en las mismas unidades que el precio (USD)
MAE	1419.42	Error absoluto medio (USD)
Algoritmo ganador	VotingEnsemble (ensamble de LightGBM, XGBoost, RandomForest y ElasticNet)	Seleccionado por AutoML entre los trials
Validación	5-fold CV	Reduce el riesgo de sobreajuste
Trials ejecutados	10	Con early termination

El modelo explica el 89,4 % de la variación del precio (R^2 = 0,894). El error típico es de USD 1.419 (MAE) y USD 1.950 (RMSE), sobre autos de USD 5.000 a 45.000 (MAPE 10,6 %). Es un resultado sólido para un dataset de solo 201 filas; la validación cruzada de 5 folds reduce el riesgo de sobreajuste.

6.1 Sobre el dataset

- UCI Automobile (imports-85): 201 filas tras descartar precios faltantes; 25 variables (marca, tipo de carrocería, motor, potencia, peso, consumo, etc.).
- AutoML aplicó imputación de faltantes, codificación one-hot de categóricas, escalado y selección de algoritmos; el conjunto es pequeño, por lo que las métricas deben tomarse como demostración.
- Riesgo de sesgo: la marca y el origen influyen en el precio; el modelo no debe usarse para decisiones comerciales sin análisis de equidad ni validación con datos actuales.

7. Respuestas a las preguntas de análisis

7.1 Ventajas de AutoML frente a programar desde cero

- Automatiza featurización, selección de algoritmos y tuning de hiperparámetros; reduce días de trabajo a minutos.
- Explora muchas familias de modelos con validación cruzada y early termination, con menos errores metodológicos.
- Incluye explicabilidad, métricas y registro versionado de cada ejecución (trazabilidad y reproducibilidad).
- Baja la barrera de entrada (perfiles sin programación) y deja el resultado listo para desplegar en Azure.

7.2 Importancia de la IA responsable

La precisión no basta: un modelo puede ser exacto y aun así discriminar o ser inexplicable. La IA responsable exige justicia (auditar sesgos por marca/segmento), confiabilidad (validación y

monitoreo de drift), privacidad (minimizar datos personales y cifrar), transparencia (explicar variables), inclusividad y responsabilidad humana. En precios o crédito, una predicción sesgada o no explicable genera pérdidas y trato injusto, además de riesgos regulatorios.

7.3 Limitaciones de los modelos sin código

- Menor flexibilidad para preprocesamientos, arquitecturas o métricas personalizadas.
- Catálogo acotado de tareas/algoritmos; difícil optimizar latencia, tamaño y costo de inferencia.
- Dependencia del proveedor (lock-in) y menor visibilidad del código interno del entrenamiento.
- En problemas grandes, el barrido de trials puede ser más caro que una solución dirigida.

7.4 Aplicación práctica en Perú

Scoring de crédito para MYPES en una caja municipal o fintech: predecir incumplimiento con ventas, flujo transaccional, rubro y región; AutoML entrega un baseline rápido y auditable, con explicabilidad por cliente para justificar decisiones. Deben cuidarse la representatividad de datos (informalidad), el sesgo geográfico, la Ley 29733 de Protección de Datos Personales y las normas de riesgo de la SBS. Otros casos: precios agrícolas (papa/café) para cooperativas, mantenimiento predictivo en minería, demanda en retail/turismo e inasistencia a citas en clínicas.

8. Costos aproximados

Recurso	Consumo	Costo
Compute DS3_v2	~0.5 h (arranque + trials)	~$0.15
Storage + Key Vault + App Insights	< 1 GB, pocas operaciones	< $0.10
Workspace AML	Sin costo fijo	$0.00
Total	Cubierto por crédito de $200	< $0.50

El clúster escala a cero tras 5 min inactivo; el grupo de recursos se elimina al finalizar (az group delete), por lo que no quedan cargos recurrentes.

9. Conclusiones, dificultades y mejoras

- Se creó el workspace, se configuró compute y se entrenó un modelo de regresión con AutoML sin código, evaluado con R^2, RMSE y MAE y registrado para su reutilización.
- AutoML acelera el ciclo y aplica buenas prácticas (CV, explicabilidad, versionado), pero el criterio humano sigue siendo clave para elegir datos, interpretar métricas y garantizar IA responsable.
- Dificultad: el CLI exige que training_data se declare como input tipado (MLTable) y no con el atajo azureml:nombre:versión; se corrigió y el job se ejecutó correctamente.

- Mejoras: ampliar el dataset, comparar con un modelo hecho a código, habilitar un endpoint gestionado con monitoreo de drift y agregar evaluación de equidad por segmentos.

10. Entregables

Repositorio GitHub (link en Blackboard): https://github.com/andr3348/CloudTask. Incluye infra/azureml (dataset, MLTable, compute.yml, automl-automobile.yml, README), docs de HW2–HW5 y este informe. El experimento queda registrado en Azure ML Studio (job serene_head_1hrtd6fdbz) y el modelo automobile-price-best en el registry.